

BioMTL 数据集文档

发布版本 v1.0

数据集名称：BioMTL

数据申请邮箱：biomtl@163.com

代码地址：<https://github.com/PPGPT/AAAI2026>

BioMTL 仅在配套数据使用协议约束下提供给非商业学术研究使用。本文档说明数据内容、文件结构、标签含义和已知局限。

1. 概述

BioMTL 是面向多任务表征学习和生理监测研究的 PPG 基准数据集。数据集包含来自 172 名受试者的 1,808 个 4 秒指尖 PPG 窗口。每个窗口关联受试者级标签，包括四项连续任务和三项二分类任务。

项目	内容
受试者	172 名，年龄范围 21-96 岁
PPG 窗口	1,808 个
信号	指尖 PPG，1000 Hz，4 秒窗口，每个窗口 4000 个采样点
任务	SBP、DBP、BG、HR、BMI、心理压力、高血压、2 型糖尿病
采集跨度	285 天
发布格式	NumPy 数组和 CSV 元数据

2. 文件结构

文件	说明
data/signals.npy	PPG 信号数组，float32 类型，形状为 (1808, 4000)。
data/window_subject.npy	每个信号窗口对应的受试者编号，int32 类型，形状为 (1808,)。
data/labels.csv	每名受试者一行，包含七项任务标签和人口学变量。
data/example_window.csv	第一个 PPG 窗口的四舍五入 CSV 示例，用于查看和绘图。
documents/en/	英文 PDF 文档和协议。
documents/zh/	中文 PDF 文档和协议。

数据对齐

signals.npy 的第 i 行对应 window_subject.npy 的第 i 个元素。该受试者编号用于与 labels.csv 连接，从而获得对应窗口的任务标签。标签为受试者级标签，同一受试者的多个窗口共享相同标签值。

3. 信号格式与预处理

- 形状为 (1808, 4000)，数据类型为 float32。
- 采样率为 1000 Hz；每行为一个 4 秒窗口，包含 4000 个采样点。
- 发布信号为经带通滤波后的 AC 幅值波形。采集处理流程采用零相位、前向-后向四阶 Butterworth 带通滤波器，通带为 0.5-8 Hz。
- 模型输入前应对每个窗口进行 z-score 标准化。
- 每名受试者提供 10 或 11 个窗口，其中 84 名受试者各 10 个窗口，88 名受试者各 11 个窗口。
- example_window.csv 是第一个信号窗口的四舍五入可读副本，不应替代 signals.npy 参与建模。

4. 标签字典

列名	类型	单位/编码	任务类别
subject_id	int	编号	主键

列名	类型	单位/编码	任务类别
n_windows	int	数量	该受试者的 PPG 窗口数
bg	float	mmol/L	血糖回归
sbp, dbp	int	mmHg	血压回归
hr	int	bpm	心率回归
bmi	float	kg/m ²	BMI 回归
weight	float	kg	人口学变量
height	float	m	人口学变量
age	int	岁	人口学变量
sex	int	0 = 女性, 1 = 男性	人口学变量
stress	int	0/1	心理压力分类
htn	int	0/1	高血压分类
t2dm	int	0/1	2 型糖尿病分类

性别计数为男性 100 名、女性 72 名。二分类阳性样本数为：心理压力 50 名，高血压 71 名，2 型糖尿病 40 名。

5. 队列统计

指标	均值	最小值	最大值	标准差
体重 (kg)	65.80	45	97	12.35
身高 (m)	1.71	1.55	1.87	0.09
年龄 (岁)	48.97	21	96	25.41
BMI (kg/m ²)	22.41	16.84	36.73	3.41
HR (bpm)	80.01	55	116	13.09
SBP (mmHg)	119.51	82	164	18.17
DBP (mmHg)	72.35	34	105	10.95
BG (mmol/L)	6.41	4.2	16.3	2.17

6. 采集方案

数据在开放环境方案下采集，以保留自然生理变化和信号变化。每个 PPG 样本与对应任务标签同步记录，并经过标准化采集和质量评估流程。

测量项目	设备
血糖	Accu-Chek Performa 毛细血管血糖仪（Roche），每日进行 L1/L2 质量控制。
血压	Omron J751 上臂式血压计。
PPG	EVAL-ADPD4100Z-PPG 开发板与 EVAL-ADPDUCZ MCU（Analog Devices），指尖采集，采样率 1 kHz。

7. 伦理与隐私

研究已通过参与临床机构伦理委员会审查，所有参与者在数据采集前均已提供知情同意。发布数据已去标识化，仅使用整数受试者编号。数据使用协议禁止任何形式的再识别尝试。

8. 预期用途

BioMTL 适用于 PPG 表征学习、多任务学习、迁移学习、小样本学习和生理监测算法研究。数据集不得直接用于临床诊断、治疗或真实患者医疗决策。

9. 已知局限

- 标签为受试者级标签，同一受试者的多个窗口共享标签值。
- 队列来自单一采集地点，可能无法代表其他人群、设备或临床环境。
- 数据不包含时间戳。
- 发布波形为经滤波处理的 AC 幅值信号；模型输入前应进行窗口级 z-score 标准化。
- 数据集仅用于算法研究和基准评测。

10. 引用与使用条件

BioMTL 的使用受数据使用协议约束。使用 BioMTL 的论文、报告或公开成果应引用关联论文：

Zhang, Z., Lu, H., & Zhao, Q. (2026). PPGPT: Transferring Next-Token Modeling from Language to PPG Signals. AAAI 40(34), 28573-28581. DOI: 10.1609/aaai.v40i34.40088.

```
@inproceedings{zhang2026ppgpt,  
  title      = {PPGPT: Transferring Next-Token Modeling from Language to PPG Signals},  
  author     = {Zhang, Zexing and Lu, Huimin and Zhao, Qingxin},  
  booktitle  = {Proceedings of the AAAI Conference on Artificial Intelligence},  
  volume    = {40},  
  number     = {34},  
  pages      = {28573--28581},  
  year       = {2026},  
  doi        = {10.1609/aaai.v40i34.40088},  
  url        = {https://ojs.aaai.org/index.php/AAAI/article/view/40088}  
}
```

版权：二〇二六年数据集贡献者。随附数据使用协议未明确授予的其他权利均予以保留。未经另行书面授权，禁止再分发、镜像或公开托管。